

A 股多因子选股与风险控制研究

按数据、信号、组合、成交、净值与评价顺序构建研究闭环

摘要 本文按照“数据-因子/信号-目标组合-回测/模拟成交-策略净值-评价与解释”的顺序，搭建一个完整、正确、可复现且可扩展的量化研究平台。基础研究在动态沪深主板资产池中，从 7 个候选因子选择 20 日低波动、5 日反转和 20 日 Amihud 非流动性，形成 Top 20 等权组合，并在停牌、涨跌停、退市与交易费用约束下逐日模拟成交。对照实验仅改变调仓频率，结果显示月频相较周频具有更低换手和成本，并取得 28.34% 年化收益、1.214 Sharpe 和 30.04% 最大回撤。拓展实验另行比较波动率目标、ERC 风险平价、权重上限、动态沪深 300 机器学习和研究工作台；其中 15% 波动率目标在收益保留与风险下降之间较均衡。机器学习结果作为附加探索报告，不改变基础研究结论。

关键词：A 股；多因子；动态资产池；Rank IC；模拟成交；交易成本；风险控制

1 研究问题与系统框架

1.1 研究目标

本项目的目标不是寻找样本内收益最高的参数，而是建立一个**完整、正确、可复现、可扩展**的研究平台。主线问题是：三个经济逻辑不同的因子能否在交易限制和费用下形成可执行组合；在保持其他条件不变时，降低调仓频率能否改善成本、回撤与稳定性。风险控制和机器学习均作为主线完成后的拓展实验。




图 1：研究框架与模块连接关系

系统将数据、因子、目标组合、成交模拟和绩效分析分离。因子模块只输出统一长表，回测模块只读取信号和配置；替换因子或组合规则时无需改写成交易核心。关键中间表保存于 DuckDB，证据输出为 CSV，并使用 SHA-256 冻结数据、代码与结果版本。

1.2 研究步骤

全文严格按照平台的数据流顺序展开：

- 数据**：确定研究范围，下载并冻结原始快照，完成复权、清洗和动态资产池；
- 因子/信号**：定义候选因子，统一方向与缺失规则，并用 IC、Rank IC 和五分组诊断；
- 目标组合**：选择三个逻辑不同的因子，形成 Top 20 等权目标；
- 回测/模拟成交**：以前一交易日信号在下一交易日开盘成交，处理现金、停牌、涨跌停、退市与费用；
- 策略净值**：逐日记录持仓、交易、成本、收益和净值并完成对账；
- 评价与解释**：报告收益、波动、Sharpe、回撤、换手和成本，再分别开展对照实验与拓展实验。

1.3 研究边界

基础实验研究上交所和深交所主板 A 股。本文未把收益率达标作为模型正确性的标准，而是优先检查唯一键、未来信息、费用对账、资产池变化和重复运行一致性。动态沪深 300 及模型实验只在拓展章节出现。

1.4 主要结果概览

主线结果是：从 7 个候选因子中选出低波动、短期反转与 Amihud 非流动性；月频三因子组合年化收益 28.34%，相较周频显著降低换手与显式成本。拓展实验中，15% 波动率目标把年化波动降至 17.99%、最大回撤降至 25.21%，同时保留 24.23% 年化收益。机器学习与网页工作台单独列为附加拓展，不与基础策略混为同一个结论。

2 数据、样本与清洗

2.1 数据范围与价格口径

数据来自 Tushare Pro。正式研究期为 2020-01-01 至 2025-12-31，下载缓冲期为 2019-10-01 至 2026-01-31，用于滚动窗口和未来收益标签。日线成交量单位为手（1 手 =100 股），成交额单位为千元。原始价、复权因

子及复权价分别保存，开盘与收盘采用同一参考因子：

$$P_{i,t}^{adj} = P_{i,t}^{raw} \frac{a_{i,t}}{a_{i,\tau}},$$

其中 $a_{i,t}$ 为复权因子， τ 为固定参考日。该口径避免把不同参考日的价格片段直接拼接。

表 1：正式下载并导入数据库的数据规模

数据集	记录数	主要用途	保存口径
日线行情	7,433,025	价格、收益、成交量与成交额	原始层
复权因子	7,579,193	统一开盘和收盘复权口径	原始层
股票基础信息	5,904	交易所、板块、上市与退市日期	参考层
交易日历	2,315	日期合法性和调仓日	参考层
历史名称	10,763	构造逐日历史 ST 状态	参考层
停牌记录	57,786	限制不可成交日期	约束层
涨跌停价格	7,482,828	判断开盘涨跌停	约束层

2.2 动态资产池与清洗规则

每个交易日依据股票代码、上市/退市日期、交易所、板块和历史名称判断是否入池。历史名称区间含 ST 标识的日期被排除；停牌记录不从资产定义中永久删除，而由成交层决定当日不可交易。每行由 `trade_date + ts_code` 唯一标识。缺失值不统一填零，成交量为零保留并单独标记。

表 2：7,433,025 条日线行情的互斥清洗对账

处理结果	记录数	占输入比例	原因与处理
缺少股票元数据	1,337	0.018%	无法可靠判断交易所、板块或上市区间，排除并记录
不属于动态研究资产池	2,663,175	35.829%	非沪深主板或不在当日上市区间，不进入研究样本
历史 ST 日期	202,719	2.727%	名称生效区间显示 ST/退市风险警示，按研究定义排除
最终保留记录	4,565,794	61.426%	满足元数据、上市区间、市场范围与非 ST 要求
对账总数	7,433,025	100.000%	四类互斥，清洗前后数量完全对应

表 3：清洗后的可验证质量提升

质量问题	输入层识别数	清洗表剩余数	改善结果
缺少股票元数据	1,337	0	保留记录均可识别资产身份与市场
资产池外记录	2,663,175	0	保留记录均符合逐日沪深主板定义
历史 ST 记录	202,719	0	研究样本与非 ST 口径一致
重复日期-资产键	检查	0	每只股票每日最多一条记录
非法价格、成交量或关键标识	检查	0	后续收益与成交计算无非法输入

清洗并非简单追求保留率，而是把无法定义、超出研究范围或与非 ST 假设冲突的记录显式隔离。动态资产池范围内，在排除历史 ST 之前共有 4,768,513 条候选记录，最终保留其中 95.75%。停牌 417 条、开盘涨停 14,712 条和开盘跌停 8,298 条没有被静默删除，而是保留状态标记并交给回测执行层处理。原始层与清洗层分开保存，9,503 个原始文件均记录大小与 SHA-256。

3 因子设计与预处理

3.1 候选因子及经济逻辑

表 4: 七个候选因子

因子	类型	方向	研究假设
20 日动量	动量	正	中短期趋势可能延续
5 日反转	反转	负近期收益	短期过度反应可能修复
20 日低波动	风险	负波动	低风险股票可能更稳定
60 日跳过 5 日动量	动量	正	中期趋势并规避短期反转
5 日隔夜反转	反转	负隔夜收益	隔夜过度反应可能在日内修复
20 日 Amihud 非流动性	流动性	正	价格冲击可能对应流动性溢价
5/20 日成交活跃度变化	成交量	正	放量可能表示新信息进入市场

每个因子均有因子卡，记录研究假设、公式、字段、窗口、预期方向、缺失规则和可能失效情形。统一输出为 `date`, `asset`, `factor`, `value`。历史不足时记缺失，不填零。

表 5: 七张因子卡：定义、数据字段与窗口

名称	研究假设	公式	字段	窗口
20 日动量	中短期强势可能延续	$C_t/C_{t-20} - 1$	复权收盘价	20 个连续交易日
5 日反转	短期过度反应可能修复	$-(C_t/C_{t-5} - 1)$	复权收盘价	5 个连续交易日
20 日低波动	低波动股票可能更稳定	$-std(r, 20)$	复权收盘价	20 个日收益
60 日跳过 5 日动量	中期趋势延续并避开短期反转	$C_{t-5}/C_{t-60} - 1$	复权收盘价	60 日，跳过最近 5 日
5 日隔夜反转	隔夜涨幅过大可能回调	$-\sum_5 \log(O_t/C_{t-1})$	复权开盘、收盘	5 个有效隔夜
20 日 Amihud 非流动性	非流动性可能要求收益补偿	$\log(mean(r /Amount, 20))$	收盘价、成交额	20 个连续交易日
5/20 日成交活跃度变化	放量可能表示新信息进入	$\log(\bar{A}_5/\bar{A}_{20})$	成交额	5 日与 20 日

表 6: 七张因子卡：方向、缺失处理与可能失效情形

名称	统一方向	缺失处理	可能失效情形
20 日动量	越高越好	历史不足 20 日或窗口含无效行则缺失	趋势快速反转或动量崩溃
5 日反转	取负后越高越好	历史不足 5 日或窗口不连续则缺失	强趋势行情
20 日低波动	波动率取负	有效日收益不足 20 个则缺失	高风险偏好或急涨行情
60 日跳过 5 日动量	越高越好	60 日窗口不完整则缺失	趋势切换或行情反转
5 日隔夜反转	隔夜收益取负	停牌、ST 或非连续交易日不跨越计算	持续信息驱动的跳空趋势
20 日 Amihud 非流动性	越高越非流动	收益缺失或成交额非正则缺失	成本吞噬溢价或小盘股混杂
5/20 日成交活跃度变化	越高越放量	20 日窗口不完整或成交额非正则缺失	投机放量后反转

3.2 截面预处理

因子公式与回测核心分离：`factor_cards.yaml` 保存说明书，`factor_config.yaml` 控制启用因子、窗口与预处理，计算模块统一输出长表。每条记录为：

date	asset	factor	value
2025-01-02	000001.SZ	low_volatility_20	-0.0126
2025-01-02	000002.SZ	reversal_5	0.0314

每日截面依次保留原始值、按 1%/99% 分位缩尾、计算 Z-score 并生成百分位排名。缩尾防止极端异常值支配结果，Z-score 用于三个因子等权合成，百分位排名用于分组与相对强弱比较。所有信号统一为“分数越高，预期收益越高”；反转和低波动因子通过取负号完成方向统一。基础版将中性化显式配置为关闭，因此可能保留行业或规模暴露，并在局限中说明。

3.3 逻辑差异

因子差异同时从经济机制、Rank 相关性和高分组重合率判断。最终三个因子分别代表风险、短期价格行为和流动性，不仅名称不同，其数据变换与可能失效机制也不同。

4 因子诊断与选择

固定持有期 h 下，在形成日 t 的有效资产集合上计算：

$$IC_t^{(h)} = \text{Corr}(f_{i,t}, y_{i,t}^{(h)}), \quad \text{RankIC}_t^{(h)} = \text{Corr}(\text{rank}(f_{i,t}), \text{rank}(y_{i,t}^{(h)})).$$

标签从下一交易日开始，构建 1、5 和 20 日未来收益。五分组按形成日因子值排序，组内等权；标签缺失不重新分组。分组诊断不连续复利为策略净值。




图 2：入选因子的 Rank IC 与五分组收益诊断

因子选择只使用 2020–2023 训练期和 2024 验证期，2025 作为选择后的测试期报告。综合 IC、Rank IC、五分组价差、覆盖率和逻辑差异，选择 **20 日低波动**、**5 日反转** 和 **20 日 Amihud 非流动性**。三者 Z-score 等权平均形成综合信号。

这里的 IC 和 t 统计量仅作描述性诊断。多日标签重叠、时间序列相关和多候选因子搜索会影响传统显著性判断，本文不将其解释为严格的因果证据或未来收益保证。

5 目标组合、模拟成交与策略净值

5.1 目标组合

综合因子每日按截面排名，调仓时选择前 20 只，基础组合目标等权。目标表只描述希望持有的资产和权重，不假设目标能够立即成交；信号形成日期、目标权重和实际成交结果分别保存。

5.2 回测与模拟成交

信号使用调仓日前一交易日收盘后数据，下一交易日开盘成交。开盘涨停不买、开盘跌停不卖、停牌或零成交量不交易，未成交旧仓继续保留。退市后仍无法卖出的持仓按零回收率核销，以避免使用陈旧价格虚增净值。

交易成本为

$$\text{Cost}_t = c_b B_t + c_s S_t,$$

其中买入费率 $c_b = 0.03\%$ ，卖出费率 $c_s = 0.13\%$ ，只对实际成交额收费。初始资金为 100 万元，无风险收益率设为 0。回测输出日收益、净值、持仓、交易日志、双边换手和累计费用。

5.3 策略净值、评价与一致性检查

报告累计和年化收益、年化波动率、Sharpe、最大回撤、换手、成本、持仓数、最大单股权重及交易次数。净值与日收益独立复核，累计收益误差约 10^{-14} ；每日费用、指标费用和累计费用误差不超过 10^{-8} 容差。目标

持仓形成日严格早于调仓日。

基础周频三因子策略年化收益 20.40%、年化波动 23.93%、Sharpe 0.897、最大回撤 40.21%。三个单因子在加入费用、交易限制和退市核销后表现明显弱于组合，说明因子诊断的排序能力不等于单一可交易策略的净收益。

为避免全样本指标掩盖时间稳定性，表 7 按研究阶段单独报告月频基础三因子组合。因子筛选只使用 2020-2023 研究期和 2024 验证期，2025 在规则冻结后才用于样本外验收。2025 样本外累计收益 66.58%，但该结果来自单一年份，不能替代跨市场状态检验；报告同时保留 16.18% 最大回撤和 21.99% 年化波动，避免只展示收益。

表 7：基础三因子组合的分阶段扣费绩效

阶段	累计收益	年化收益	年化波动	最大回撤
研究期（2020–2023）	163.91%	27.39%	19.13%	27.60%
验证期（2024）	1.99%	1.99%	33.90%	29.63%
冻结样本外（2025）	66.58%	66.23%	21.99%	16.18%

6 对照实验：周频与月频

6.1 实验设计

对照实验只改变调仓频率：周频使用每周首个交易日，月频使用每月首个交易日。两组共用相同数据快照、2020-2025 样本、动态资产池、三因子、Top 20 等权目标、费率和成交限制。自动检查确认两组均覆盖 1,455 个交易日，无未来信息；周频 307 次调仓，月频 71 次调仓。



图 3：周频与月频三因子策略的净值和回撤

表 8: 周频与月频对照结果

指标	周频	月频
累计收益	205.38%	348.34%
年化收益	20.40%	28.34%
年化波动率	23.93%	22.71%
Sharpe	0.897	1.214
最大回撤	40.21%	30.04%
总换手	517.51	130.55
显式交易成本	691,116 元	233,288 元
交易次数	11,304	2,707

6.2 同成交路径的成本归因

沿用净回测实际成交日期、价格和数量，仅把累计已付费用作为未投资现金加回，不重新成交。周频毛累计收益 274.49%、净收益 205.38%，成本拖累 69.11 个百分点；月频毛收益 371.67%、净收益 348.34%，拖累 23.33 个百分点。月频优势与较低换手和成本一致，但频率也改变持仓路径，因此不能把全部收益差异归因于费用。月频并非每年均胜出，结论属于描述性对照。

7 拓展实验

所有拓展均在基础三因子策略和周频/月频对照完成后单列，不改变基础任务的研究结论。

7.1 拓展一：波动率目标

固定月频三因子 Top 20 股票集合，比较等权与 10%/15%/20% 波动率目标。风险估计只使用形成日及以前 60 个交易日，至少 40 个有效观测。波动率目标股票仓位为

$$E_t = \min\left(1, \frac{\sigma^*}{\widehat{\sigma}_{t-1}}\right),$$

不使用杠杆，剩余资金作为零收益现金。

7.2 拓展二：ERC 风险平价

使用完整协方差矩阵和轻度收缩估计风险贡献，使 Top 20 内部各股票的边际风险贡献更接近。该实验回答“内部风险重分配是否优于简单等权”，与总仓位波动率控制分开解释。

7.3 拓展三：单股权重上限与组合方案

在 ERC 上加入 8% 目标权重上限，并进一步与 15% 波动率目标组合。8% 是调仓时目标而非每日实际权重保证；价格变化或交易受限可能造成事后超限。




图 4: 显式成本拖累与风险拓展的收益-风险比较

表 9: 组合与风险拓展结果

方案	年化收益	年化波动	Sharpe	最大回撤	成本（元）
月频等权	28.34%	22.71%	1.214	30.04%	233,288
10% 波动率目标	17.57%	13.09%	1.303	18.09%	109,377
15% 波动率目标	24.23%	17.99%	1.296	25.21%	176,264
20% 波动率目标	26.85%	20.50%	1.264	28.23%	208,193
ERC 风险平价	26.76%	22.05%	1.187	28.06%	227,592
ERC+8% 上限	26.79%	22.07%	1.187	28.06%	227,341
ERC+ 上限 +15% 目标	23.75%	18.15%	1.266	24.28%	179,292

拓展结果分点解释如下：

- **波动率目标：**10% 目标获得最高 Sharpe 和最低回撤，但平均现金比例 38.74%，收益牺牲较大；15% 目标平均现金约 17.06%，在收益保留和风险下降之间更均衡。
- **ERC 风险平价：**没有改善 Sharpe，说明本样本的风险改善主要来自降低总体股票暴露，而非 Top 20 内部重分配。
- **权重上限：**8% 上限对结果影响有限，说明基础 Top 20 组合本身并未形成严重的目标权重集中。

7.4 拓展四：动态沪深 300 与机器学习

时点数据、因子与训练设计。 模型拓展使用 73 个月历史成分权重快照，涉及 398 只历史成分股；成分从生效日向后使用，财务指标按公告日做 as-of 连接。10 个输入因子覆盖量价、价值和质量，每个信号日依次缩尾、行业与市值中性化并标准化。训练严格按时间推进：2020–2022 为初始训练，2023–2024 用于参数和组合规则选择，2025 仅作一次冻结样本外测试。每月扩展窗口重新训练，但只有未来 20 日标签已完整退出的样本可以进入训练。

Ridge 提供线性基准，LightGBM 学习非线性与交互关系。验证期最优 LightGBM 参数的 Rank IC 为 0.0486，而 Ridge 约为 -0.0042。Qlib 0.9.7 作为因子研究接口，首批透明复算 21 个 Alpha158 OHLCV 表达式；2025 月度 Rank IC 较高者包括 RSV20 (0.079)、RSV5 (0.063) 和 WVMA20 (0.039)。这些结果只作为下一轮候选，不回填已经冻结的 2025 策略。

逐日执行与状态切换。 月末收盘形成目标，下一交易日开盘成交；开盘涨停不买、跌停不卖，停牌或零成交阻断订单，现金和残留持仓逐日对账。验证期选定 126 日相对强弱状态规则，每月只切换一次：弱状态持有沪深 300，强状态切换到防御型 LightGBM Top10，切换另按 16bp 保守收费。该规则在查看 2025 结果前冻结。




图 5: 动态沪深 300 状态切换策略与冻结样本外结果

表 10: 状态切换策略与沪深 300 对比

期间	策略	累计收益	年化收益	最大回撤	Sharpe
2023–2024 验证	状态切换	6.87%	3.38%	23.53%	0.280
2023–2024 验证	沪深 300	1.63%	0.81%	24.80%	0.133
2025 冻结测试	状态切换	25.51%	25.40%	11.02%	1.545
2025 冻结测试	沪深 300	17.66%	17.58%	10.49%	1.159

7.5 拓展五：Qlib 因子库与研究工作台

Qlib 仅作为新因子研究接口，当前 21 个透明表达式的诊断结果不回填正式基础策略。网页研究工作台直接读取审计 CSV，允许切换基础结果、风险拓展及模型候选，并同步显示净值、回撤和指标；网页不重新计算绩效。同花顺部分仅导出待人工复核的模拟订单清单，不自动登录或下单。

8 结论、局限与复现

8.1 主要结论

主线结论只有两点：其一，低波动、短期反转和流动性三个维度形成逻辑互补的基础信号；其二，在其他条件一致时，月频相较周频具有更低换手、成本和回撤。拓展实验另行表明 15% 波动率目标能在收益保留与风险下降间取得平衡；ERC 和权重上限没有改善 Sharpe。动态沪深 300 机器学习结果属于附加探索，不作为基础三因子策略成立的必要条件。

8.2 局限与下一步

基础回测未建模冲击成本、滑点和 100 股整手约束，现金收益设为 0，历史 ST 依赖名称区间，退市残余持仓按零回收。模型拓展虽已做行业与市值中性化和逐日开盘撮合，但仍缺少冲击成本、整手约束与真实模拟账户成交验证。传统 t 统计量未修正重叠标签、自相关和多重搜索。下一步将 Qlib 候选因子放入新的扩展窗口，并以新增 2026 数据建立新的最终留出期，而不是继续利用 2025 调参。

8.3 复现信息

项目提供测试、下载、清洗、资产池、因子、诊断、回测、模型拓展、网页和最终复现包入口。原始数据共有 9,503 个文件并逐项记录 SHA-256；另提供 10 只股票、57 个交易日的离线小样本。最终清单记录源码、配置、文档、证据输出和 DuckDB 引用，并在元数据中写入 Git 提交及生成前工作区状态。

表 11: 主要复现入口

模块	入口
因子构建	scripts/05_factors/05_run_factor_pipeline.py
因子诊断	scripts/06_evaluation/06_run_evaluation_pipeline.py
基础回测	scripts/07_backtest/06_run_backtest_pipeline.py
对照实验	scripts/08_experiments/04_run_weekly_vs_monthly_experiment.py
风险拓展	scripts/09_extensions/04_run_portfolio_risk_extension.py
模型拓展	scripts/08_experiments/10_run_regime_overlay.py
Qlib 诊断	scripts/08_experiments/12_run_qlib_alpha158_subset.py
最终复现包	scripts/10_reproducibility/04_run_final_reproduction_package.py

8.4 课程要求与验收证据索引

为避免仅声明“已经完成”，表 12 将课程要求直接对应到可核验的报告证据与复现产物。

表 12: 课程要求-报告证据对照

课程要求	本报告中的直接证据	可复现产物
数据接入、清洗与质量报告	第 2 节的数据规模、互斥清洗对账、唯一键与异常处理	原始/清洗表、质量报告、SHA-256 清单
三个逻辑不同的因子及诊断	第 3-4 节因子卡、统一方向、IC、Rank IC 与五分组	因子长表、诊断 CSV 和图片
可配置回测与绩效分析	第 5 节信号时点、持仓、费用、成交限制与一致性检查	YAML 配置、交易日志、净值与指标表
小型对照实验	第 6 节周频与月频仅改变调仓频率的对照	两组同口径配置和检查输出
自主拓展	第 7 节分点列出的波动率目标、ERC、权重上限、模型与工作台	风险拓展、模型审计、Qlib 诊断和网页
复现包与研究报告	第 8 节入口、环境、快照、小样本及校验值	README、一键入口、清单和离线小样本