

动态沪深 300 多因子与机器学习策略研究

从基础因子框架到 Ridge、LightGBM 与逐日成交回测

摘要 本文搭建了一个从 Tushare 时点数据、清洗与复权、动态资产池、因子诊断、模型训练到逐日成交和可视化审计的完整量化投研平台。基础实验在沪深主板中构建低波动、短期反转和 Amihud 非流动性三因子组合，以周频与月频对照及波动率目标检验成本和风险。自主拓展将研究对象收敛为历史动态沪深 300，加入估值、质量、动量等 10 个行业与市值中性化因子，以 2020-2022 训练、2023-2024 验证、2025 冻结测试的扩展窗口训练 Ridge 与 LightGBM，并使用逐日开盘成交器处理现金、停牌、涨跌停和费用。验证期选定的 126 日相对强弱状态切换策略在 2025 年扣费后累计收益 25.51%、年化 25.40%、最大回撤 11.02%、Sharpe 1.545；同期沪深 300 累计 17.66%、年化 17.58%。该结果仅是一次冻结样本外证据，不构成未来收益保证。

关键词：动态沪深 300；多因子；Ridge；LightGBM；逐日回测；交易成本；Qlib

1 研究问题与系统框架

1.1 研究目标

本项目的目标不是寻找样本内收益最高的参数，而是建立一个**完整、正确、可复现、可扩展**的研究平台。基础层回答三个逻辑不同的因子能否在交易限制和费用下形成可执行组合；拓展层进一步回答 Ridge 和 LightGBM 能否在历史动态沪深 300 中形成严格时间隔离、可逐日成交且相对基准有增量的策略。




图 1：研究框架与模块连接关系

系统将数据、因子、目标组合、成交模拟和绩效分析分离。因子模块只输出统一长表，回测模块只读取信号和配置；替换因子或组合规则时无需改写成成交核心。关键中间表保存于 DuckDB，证据输出为 CSV，并使用 SHA-256 冻结数据、代码与结果版本。

1.2 研究边界

基础实验研究上交所和深交所主板 A 股；模型拓展只使用每个历史时点已生效的沪深 300 成分股。本文未把收益率达标作为模型正确性的标准，而是优先检查唯一键、公告日和成分时点、标签退出日、费用对账、资产池变化和重复运行一致性。

1.3 主要结果概览

研究形成两层证据：基础层从 7 个候选因子中选出低波动、短期反转与 Amihud 非流动性，月频组合取得 28.34% 年化收益，15% 波动率目标将年化波动降至 17.99%；拓展层使用动态沪深 300、10 个中性化因子和 Ridge/LightGBM，最终状态切换策略在 2025 冻结测试中累计收益 25.51%，相对沪深 300 高 7.85 个百分点。后文同时保留基础任务证据和模型拓展的时间隔离、逐日执行与网页审计结果。

2 数据、样本与清洗

2.1 数据范围与价格口径

数据来自 Tushare Pro。正式研究期为 2020-01-01 至 2025-12-31，下载缓冲期为 2019-10-01 至 2026-01-31，用于滚动窗口和未来收益标签。日线成交量单位为手（1 手 = 100 股），成交额单位为千元。原始价、复权因子及复权价分别保存，开盘与收盘采用同一参考因子：

$$P_{i,t}^{adj} = P_{i,t}^{raw} \frac{a_{i,t}}{a_{i,\tau}}$$

其中 $a_{i,t}$ 为复权因子， τ 为固定参考日。该口径避免把不同参考日的价格片段直接拼接。

表 1: 正式下载并导入数据库的数据规模

数据集	记录数	主要用途	保存口径
日线行情	7,433,025	价格、收益、成交量与成交额	原始层
复权因子	7,579,193	统一开盘和收盘复权口径	原始层
股票基础信息	5,904	交易所、板块、上市与退市日期	参考层
交易日历	2,315	日期合法性和调仓日	参考层
历史名称	10,763	构造逐日历史 ST 状态	参考层
停牌记录	57,786	限制不可成交日期	约束层
涨跌停价格	7,482,828	判断开盘涨跌停	约束层

2.2 动态资产池与清洗规则

每个交易日依据股票代码、上市/退市日期、交易所、板块和历史名称判断是否入池。历史名称区间含 ST 标识的日期被排除；停牌记录不从资产定义中永久删除，而由成交层决定当日不可交易。每行由 `trade_date + ts_code` 唯一标识。缺失值不统一填零，成交量为零保留并单独标记。

表 2: 7,433,025 条日线行情的互斥清洗对账

处理结果	记录数	占输入比例	原因与处理
缺少股票元数据	1,337	0.018%	无法可靠判断交易所、板块或上市区间，排除并记录
不属于动态研究资产池	2,663,175	35.829%	非沪深主板或不在当日上市区间，不进入研究样本
历史 ST 日期	202,719	2.727%	名称生效区间显示 ST/退市风险警示，按研究定义排除
最终保留记录	4,565,794	61.426%	满足元数据、上市区间、市场范围与非 ST 要求
对账总数	7,433,025	100.000%	四类互斥，清洗前后数量完全对应

表 3: 清洗后的可验证质量提升

质量问题	输入层识别数	清洗表剩余数	改善结果
缺少股票元数据	1,337	0	保留记录均可识别资产身份与市场
资产池外记录	2,663,175	0	保留记录均符合逐日沪深主板定义
历史 ST 记录	202,719	0	研究样本与非 ST 口径一致
重复日期-资产键	检查	0	每只股票每日最多一条记录
非法价格、成交量或关键标识	检查	0	后续收益与成交计算无法非法输入

清洗并非简单追求保留率，而是把无法定义、超出研究范围或与非 ST 假设冲突的记录显式隔离。动态资产池范围内，在排除历史 ST 之前共有 4,768,513 条候选记录，最终保留其中 95.75%。停牌 417 条、开盘涨停 14,712 条和开盘跌停 8,298 条没有被静默删除，而是保留状态标记并交给回测执行层处理。原始层与清洗层分开保存，9,503 个原始文件均记录大小与 SHA-256。

3 因子设计与预处理

3.1 候选因子及经济逻辑

表 4: 七个候选因子

因子	类型	方向	研究假设
20 日动量	动量	正	中短期趋势可能延续
5 日反转	反转	负近期收益	短期过度反应可能修复
20 日低波动	风险	负波动	低风险股票可能更稳定
60 日跳过 5 日动量	动量	正	中期趋势并规避短期反转
5 日隔夜反转	反转	负隔夜收益	隔夜过度反应可能在日内修复
20 日 Amihud 非流动性	流动性	正	价格冲击可能对应流动性溢价
5/20 日成交活跃度变化	成交量	正	放量可能表示新信息进入市场

每个因子均有因子卡，记录研究假设、公式、字段、窗口、预期方向、缺失规则和可能失效情形。统一输出为 `date, asset, factor, value`。历史不足时记缺失，不填零。

表 5: 七张因子卡：定义、数据字段与窗口

名称	研究假设	公式	字段	窗口
20 日动量	中短期强势可能延续	$C_t/C_{t-20} - 1$	复权收盘价	20 个连续交易日
5 日反转	短期过度反应可能修复	$-(C_t/C_{t-5} - 1)$	复权收盘价	5 个连续交易日
20 日低波动	低波动股票可能更稳定	$-std(r, 20)$	复权收盘价	20 个日收益
60 日跳过 5 日动量	中期趋势延续并避开短期反转	$C_{t-5}/C_{t-60} - 1$	复权收盘价	60 日，跳过最近 5 日
5 日隔夜反转	隔夜涨幅过大可能回调	$-\sum_5 \log(O_t/C_{t-1})$	复权开盘、收盘	5 个有效隔夜
20 日 Amihud 非流动性	非流动性可能要求收益补偿	$\log(mean(r /Amount, 20))$	收盘价、成交额	20 个连续交易日
5/20 日成交活跃度变化	放量可能表示新信息进入	$\log(\bar{A}_5/\bar{A}_{20})$	成交额	5 日与 20 日

表 6: 七张因子卡：方向、缺失处理与可能失效情形

名称	统一方向	缺失处理	可能失效情形
20 日动量	越高越好	历史不足 20 日或窗口含无效行则缺失	趋势快速反转或动量崩溃
5 日反转	取负后越高越好	历史不足 5 日或窗口不连续则缺失	强趋势行情
20 日低波动	波动率取负	有效日收益不足 20 个则缺失	高风险偏好或急涨行情
60 日跳过 5 日动量	越高越好	60 日窗口不完整则缺失	趋势切换或行情反转
5 日隔夜反转	隔夜收益取负	停牌、ST 或非连续交易日不跨越计算	持续信息驱动的跳空趋势
20 日 Amihud 非流动性	越高越非流动	收益缺失或成交额非正则缺失	成本吞噬溢价或小盘股混杂
5/20 日成交活跃度变化	越高越放量	20 日窗口不完整或成交额非正则缺失	投机放量后反转

3.2 截面预处理

因子公式与回测核心分离：`factor_cards.yaml` 保存说明书，`factor_config.yaml` 控制启用因子、窗口与预处理，计算模块统一输出长表。每条记录为：

date	asset	factor	value
2025-01-02	000001.SZ	low_volatility_20	-0.0126
2025-01-02	000002.SZ	reversal_5	0.0314

每日截面依次保留原始值、按 1%/99% 分位缩尾、计算 Z-score 并生成百分位排名。缩尾防止极端异常值支配结果，Z-score 用于三个因子等权合成，百分位排名用于分组与相对强弱比较。所有信号统一为“分数越高，预期收益越高”；反转和低波动因子通过取负号完成方向统一。基础版将中性化显式配置为关闭，因此可能保留行业或规模暴露，并在局限中说明。

3.3 逻辑差异

因子差异同时从经济机制、Rank 相关性和高分组重合率判断。最终三个因子分别代表风险、短期价格行为和流动性，不仅名称不同，其数据变换与可能失效机制也不同。

4 因子诊断与选择

固定持有期 h 下，在形成日 t 的有效资产集合上计算：

$$IC_t^{(h)} = \text{Corr}(f_{i,t}, y_{i,t}^{(h)}), \quad \text{RankIC}_t^{(h)} = \text{Corr}(\text{rank}(f_{i,t}), \text{rank}(y_{i,t}^{(h)})).$$

标签从下一交易日开始，构建 1、5 和 20 日未来收益。五分组按形成日因子值排序，组内等权；标签缺失不重新分组。分组诊断不连续复利为策略净值。




图 2：入选因子的 Rank IC 与五分组收益诊断

因子选择只使用 2020–2023 训练期和 2024 验证期，2025 作为选择后的测试期报告。综合 IC、Rank IC、五分组价差、覆盖率和逻辑差异，选择 **20 日低波动**、**5 日反转** 和 **20 日 Amihud 非流动性**。三者 Z-score 等权平均形成综合信号。

这里的 IC 和 t 统计量仅作描述性诊断。多目标标签重叠、时间序列相关和多候选因子搜索会影响传统显著性判断，本文不将其解释为严格的因果证据或未来收益保证。

5 策略构建与基础回测

5.1 组合与成交规则

综合因子每日按截面排名，调仓时选择前 20 只，基础组合目标等权。信号使用调仓日前一交易日收盘后数据，下一交易日开盘成交。开盘涨停不买、开盘跌停不卖、停牌或零成交量不交易，未成交旧仓继续保留。退市后仍无法卖出的持仓按零回收率核销，以避免使用陈旧价格虚增净值。

交易成本为

$$\text{Cost}_t = c_b B_t + c_s S_t,$$

其中买入费率 $c_b = 0.03\%$ ，卖出费率 $c_s = 0.13\%$ ，只对实际成交额收费。初始资金为 100 万元，无风险收益率设为 0。回测输出日收益、净值、持仓、交易日志、双边换手和累计费用。

5.2 绩效与一致性检查

报告累计和年化收益、年化波动率、Sharpe、最大回撤、换手、成本、持仓数、最大单股权重及交易次数。净值与日收益独立复核，累计收益误差约 10^{-14} ；每日费用、指标费用和累计费用误差不超过 10^{-8} 容差。目标持仓形成日严格早于调仓日。

基础周频三因子策略年化收益 20.40%、年化波动 23.93%、Sharpe 0.897、最大回撤 40.21%。三个单因

子在加入费用、交易限制和退市核销后表现明显弱于组合，说明因子诊断的排序能力不等于单一可交易策略的净收益。

6 对照实验：周频与月频

6.1 实验设计

对照实验只改变调仓频率：周频使用每周首个交易日，月频使用每月首个交易日。两组共用相同数据快照、2020–2025 样本、动态资产池、三因子、Top 20 等权目标、费率和成交限制。自动检查确认两组均覆盖 1,455 个交易日，无未来信息；周频 307 次调仓，月频 71 次调仓。



图 3：周频与月频三因子策略的净值和回撤

表 7：周频与月频对照结果

指标	周频	月频
累计收益	205.38%	348.34%
年化收益	20.40%	28.34%
年化波动率	23.93%	22.71%
Sharpe	0.897	1.214
最大回撤	40.21%	30.04%
总换手	517.51	130.55
显式交易成本	691,116 元	233,288 元
交易次数	11,304	2,707

6.2 同成交路径的成本归因

沿用净回测实际成交日期、价格和数量，仅把累计已付费用作为未投资现金加回，不重新成交。周频毛累计收益 274.49%、净收益 205.38%，成本拖累 69.11 个百分点；月频毛收益 371.67%、净收益 348.34%，拖累 23.33 个百分点。月频优势与较低换手和成本一致，但频率也改变持仓路径，因此不能把全部收益差异归因于费用。月频并非每年均胜出，结论属于描述性对照。

7 自主拓展：组合与风险

7.1 设计与方法

拓展固定月频三因子 Top 20 股票集合，仅改变组合层，比较等权、10%/15%/20% 波动率目标、完整协方差矩阵的 ERC 风险平价、8% 目标权重上限及组合方案。风险估计使用形成日及以前 60 个交易日，至少 40 个有效观测，并对协方差矩阵轻度收缩。波动率目标股票仓位为

$$E_t = \min \left(1, \frac{\sigma^*}{\hat{\sigma}_{t-1}} \right),$$

不使用杠杆，剩余资金作为零收益现金。




图 4：显式成本拖累与风险拓展的收益–风险比较

表 8：组合与风险拓展结果

方案	年化收益	年化波动	Sharpe	最大回撤	成本（元）
月频等权	28.34%	22.71%	1.214	30.04%	233,288
10% 波动率目标	17.57%	13.09%	1.303	18.09%	109,377
15% 波动率目标	24.23%	17.99%	1.296	25.21%	176,264
20% 波动率目标	26.85%	20.50%	1.264	28.23%	208,193
ERC 风险平价	26.76%	22.05%	1.187	28.06%	227,592
ERC+8% 上限	26.79%	22.07%	1.187	28.06%	227,341
ERC+ 上限 +15% 目标	23.75%	18.15%	1.266	24.28%	179,292

10% 目标获得最高 Sharpe 和最低回撤，但平均现金比例 38.74%，收益牺牲较大；15% 目标平均现金约 17.06%，在收益保留和风险下降之间更均衡。ERC 及 8% 目标上限未改善 Sharpe，说明本样本的主要风险改善来自总股票暴露控制，而非 Top 20 内部重分配。8% 是调仓目标而非每日实际权重保证；价格变化或交易受限可能造成事后超限。

8 模型拓展：动态沪深 300 与逐日回测

8.1 时点数据、因子与训练设计

模型拓展使用 73 个月历史成分权重快照，涉及 398 只历史成分股；成分从生效日向后使用，财务指标按公告日做 as-of 连接。10 个输入因子覆盖量价、价值和质量，每个信号日依次缩尾、行业与市值中性化并标准化。训练严格按时间推进：2020–2022 为初始训练，2023–2024 用于参数和组合规则选择，2025 仅作一次冻结样本外测试。每月扩展窗口重新训练，但只有未来 20 日标签已完整退出的样本可以进入训练。

Ridge 提供线性基准，LightGBM 学习非线性与交互关系。验证期最优 LightGBM 参数的 Rank IC 为 0.0486，而 Ridge 约为 −0.0042。Qlib 0.9.7 作为因子研究接口，首批透明复算 21 个 Alpha158 OHLCV 表

达式；2025 月度 Rank IC 较高者包括 RSV20（0.079）、RSV5（0.063）和 WVMA20（0.039）。这些结果只作为下一轮候选，不回填已经冻结的 2025 策略。

8.2 逐日执行与状态切换

月末收盘形成目标，下一交易日开盘成交；开盘涨停不买、跌停不卖，停牌或零成交阻断订单，现金和残留持仓逐日对账。验证期选定 126 日相对强弱状态规则，每月只切换一次：弱状态持有沪深 300，强状态切换到防御型 LightGBM Top10，切换另按 16bp 保守收费。该规则在查看 2025 结果前冻结。



图 5：动态沪深 300 状态切换策略与冻结样本外结果

表 9：状态切换策略与沪深 300 对比

期间	策略	累计收益	年化收益	最大回撤	Sharpe
2023–2024 验证	状态切换	6.87%	3.38%	23.53%	0.280
2023–2024 验证	沪深 300	1.63%	0.81%	24.80%	0.133
2025 冻结测试	状态切换	25.51%	25.40%	11.02%	1.545
2025 冻结测试	沪深 300	17.66%	17.58%	10.49%	1.159

网页研究工作台直接读取上述审计 CSV，允许切换状态策略、Ridge、LightGBM 及沪深 300，并同步显示净值、回撤和指标。网页不重新计算绩效，因此报告、网页和演示使用同一组冻结数字。

9 结论、局限与复现

9.1 主要结论

本文得到四点描述性结论：其一，低波动、短期反转和流动性三个维度可以形成逻辑互补的基础信号；其二，月频比周频更适合该信号，表现为更低换手、成本和回撤；其三，15% 波动率目标能在收益保留与风险下降间取得平衡；其四，动态沪深 300 模型中，验证期冻结的状态切换策略在 2025 扣费后跑赢基准，但回撤 11.02% 略高于沪深 300 的 10.49%，不能据此保证未来继续产生超额收益。

9.2 局限与下一步

基础回测未建模冲击成本、滑点和 100 股整手约束，现金收益设为 0，历史 ST 依赖名称区间，退市残余持仓按零回收。模型拓展虽已做行业与市值中性化和逐日开盘撮合，但仍缺少冲击成本、整手约束与真实模拟账户成交验证。传统 t 统计量未修正重叠标签、自相关和多重搜索。下一步将 Qlib 候选因子放入新的扩展窗口，并以新增 2026 数据建立新的最终留出期，而不是继续利用 2025 调参。

9.3 复现信息

项目提供测试、下载、清洗、资产池、因子、诊断、回测、模型拓展、网页和最终复现包入口。原始数据共有 9,503 个文件并逐项记录 SHA-256；另提供 10 只股票、57 个交易日的离线小样本。最终清单记录源码、配

置、文档、证据输出和 DuckDB 引用，并在元数据中写入 Git 提交及生成前工作区状态。

表 10: 主要复现入口

模块	入口
因子构建	scripts/05_factors/05_run_factor_pipeline.py
因子诊断	scripts/06_evaluation/06_run_evaluation_pipeline.py
基础回测	scripts/07_backtest/06_run_backtest_pipeline.py
对照实验	scripts/08_experiments/04_run_weekly_vs_monthly_experiment.py
风险拓展	scripts/09_extensions/04_run_portfolio_risk_extension.py
模型拓展	scripts/08_experiments/10_run_regime_overlay.py
Qlib 诊断	scripts/08_experiments/12_run_qlib_alpha158_subset.py
最终复现包	scripts/10_reproducibility/04_run_final_reproduction_package.py

9.4 课程要求与验收证据索引

为避免仅声明“已经完成”，表 11 将课程要求直接对应到可核验的报告证据与复现产物。

表 11: 课程要求-报告证据对照

课程要求	本报告中的直接证据	可复现产物
数据接入、清洗与质量报告	第 2 节的数据规模、互斥清洗对账、唯一键与异常处理	原始/清洗表、质量报告、SHA-256 清单
三个逻辑不同的因子及诊断	第 3-4 节因子卡、统一方向、IC、Rank IC 与五分组	因子长表、诊断 CSV 和图片
可配置回测与绩效分析	第 5 节信号时点、持仓、费用、成交限制与一致性检查	YAML 配置、交易日志、净值与指标表
小型对照实验	第 6 节周频与月频仅改变调仓频率的对照	两组同口径配置和检查输出
自主拓展	第 7-8 节风险控制、动态沪深 300、Ridge/LightGBM 与逐日执行	风险拓展、模型审计、Qlib 诊断和网页
复现包与研究报告	第 9 节入口、环境、快照、小样本及校验值	README、一键入口、清单和离线小样本